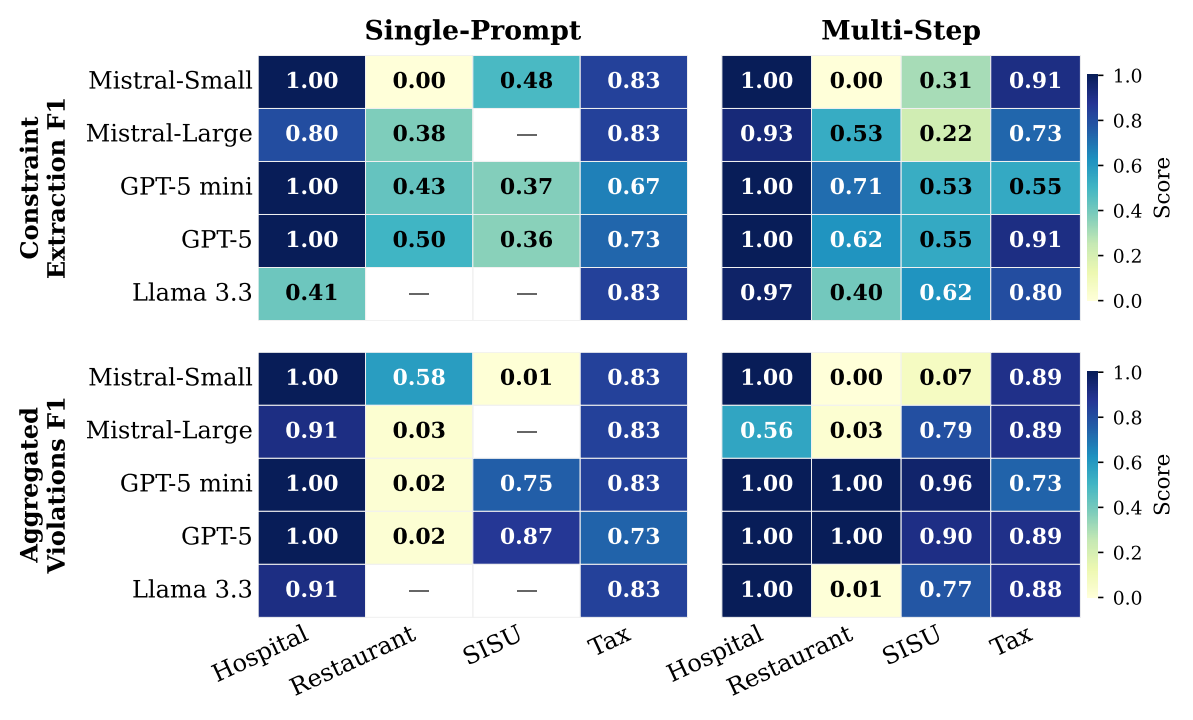
Single-Prompt
Multi-Step
Constraint Extraction F1
Aggregated Violations F1
Mistral-Small
Mistral-Large
GPT-5 mini
GPT-5
Llama 3.3
1.00 0.00 0.48 0.83
0.80 0.38 — 0.83
1.00 0.43 0.37 0.67
1.00 0.50 0.36 0.73
0.41 — — 0.83
1.00 0.00 0.31 0.91
0.93 0.53 0.22 0.73
1.00 0.71 0.53 0.55
1.00 0.62 0.55 0.91
0.97 0.40 0.62 0.80
1.00 0.58 0.01 0.83
0.91 0.03 — 0.83
1.00 0.02 0.75 0.83
1.00 0.02 0.87 0.73
0.91 — — 0.83
1.00 0.00 0.07 0.89
0.56 0.03 0.79 0.89
1.00 1.00 0.96 0.73
1.00 1.00 0.90 0.89
1.00 0.01 0.77 0.88
Score
1.0
0.8
0.6
0.4
0.2
0.0
Hospital
Restaurant
SISU
Tax