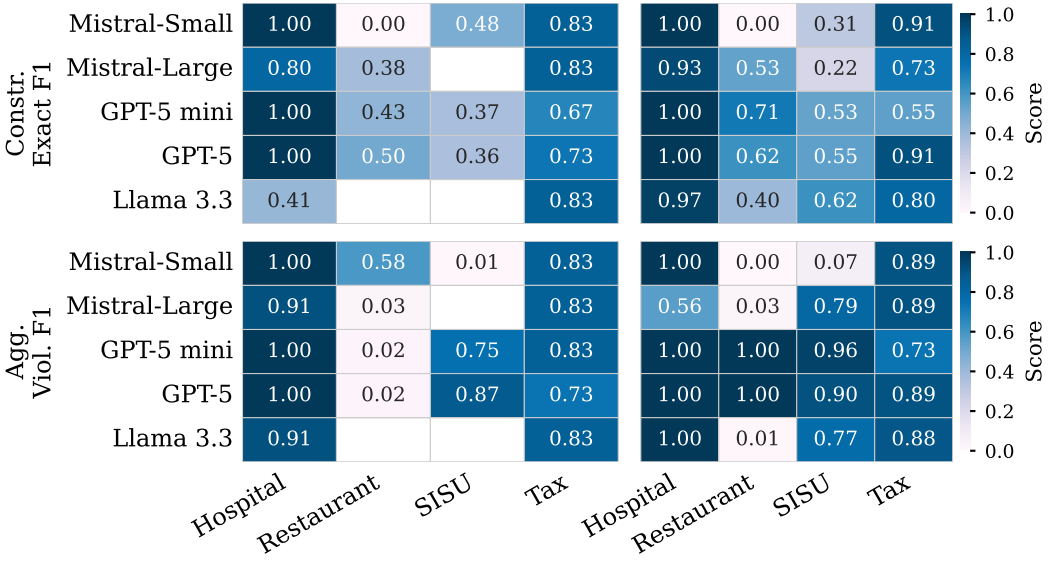
Single-Prompt
MultiStep
Constr. Exact F1
Agg. Viol. F1
Mistral-Small
Mistral-Large
GPT-5 mini
GPT-5
Llama 3.3
1.00 0.00 0.48 0.83
0.80 0.38 0.83
1.00 0.43 0.37 0.67
1.00 0.50 0.36 0.73
0.41 0.83
1.00 0.00 0.31 0.91
0.93 0.53 0.22 0.73
1.00 0.71 0.53 0.55
1.00 0.62 0.55 0.91
0.97 0.40 0.62 0.80
1.00 0.58 0.01 0.83
0.91 0.03 0.83
1.00 0.02 0.75 0.83
1.00 0.02 0.87 0.73
0.91 0.83
1.00 0.00 0.07 0.89
0.56 0.03 0.79 0.89
1.00 1.00 0.96 0.73
1.00 1.00 0.90 0.89
1.00 0.01 0.77 0.88
Score
1.0
0.8
0.6
0.4
0.2
0.0
Hospital
Restaurant
SISU
Tax