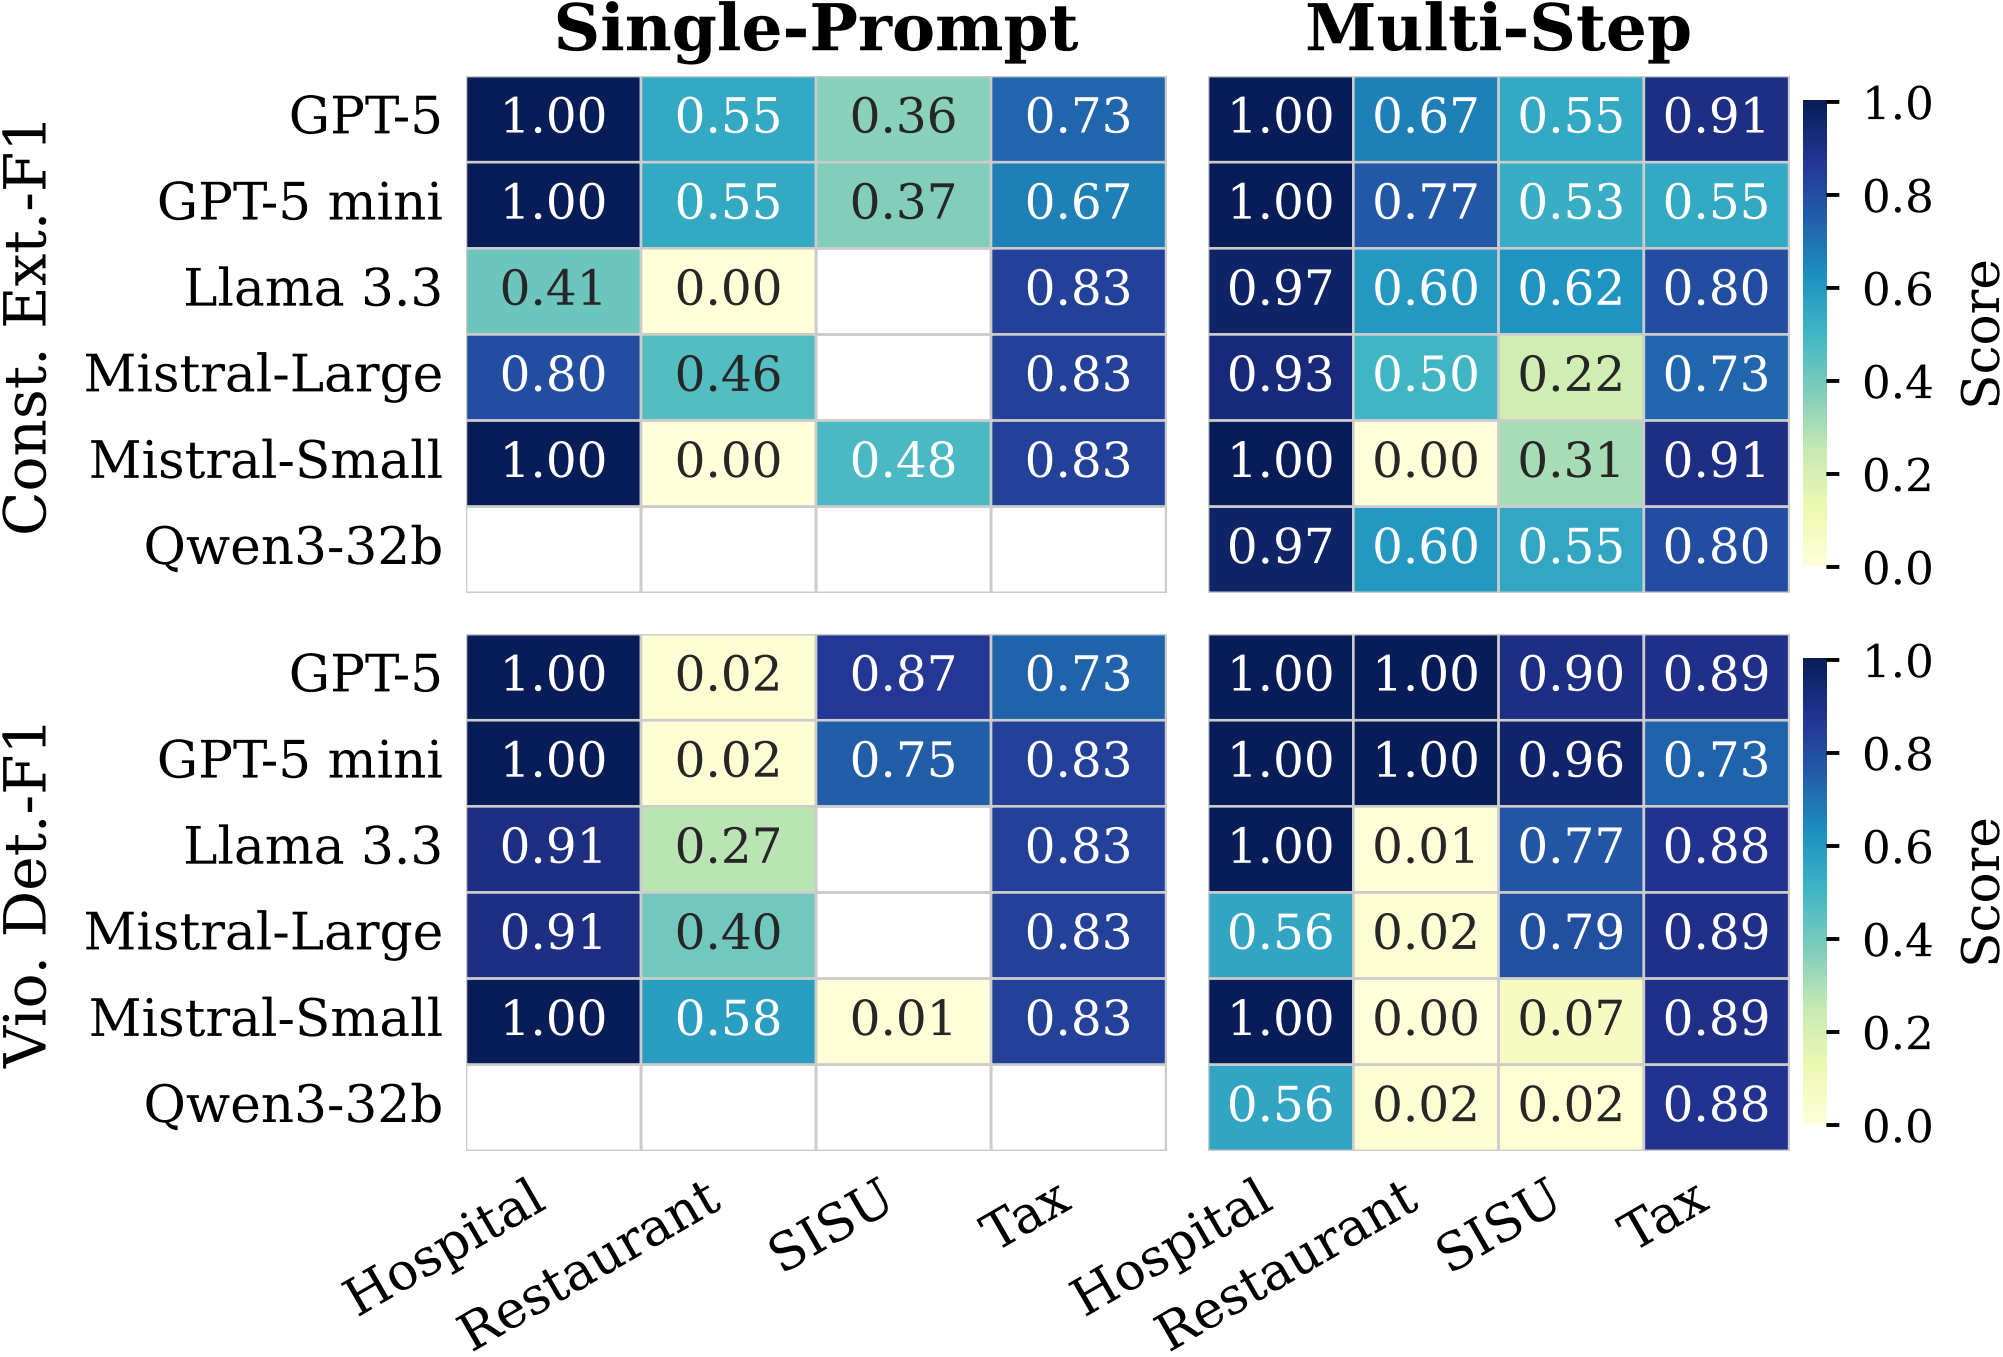
Single-Prompt
Multi-Step
Const. Ext.-F1
Vio. Det.-F1
GPT-5
GPT-5 mini
Llama 3.3
Mistral-Large
Mistral-Small
Qwen3-32b
1.00 0.55 0.36 0.73
1.00 0.55 0.37 0.67
0.41 0.00 0.83
0.80 0.46 0.83
1.00 0.00 0.48 0.83
1.00 0.67 0.55 0.91
1.00 0.77 0.53 0.55
0.97 0.60 0.62 0.80
0.93 0.50 0.22 0.73
1.00 0.00 0.31 0.91
0.97 0.60 0.55 0.80
1.00 0.02 0.87 0.73
1.00 0.02 0.75 0.83
0.91 0.27 0.83
0.91 0.40 0.83
1.00 0.58 0.01 0.83
1.00 1.00 0.90 0.89
1.00 1.00 0.96 0.73
1.00 0.01 0.77 0.88
0.56 0.02 0.79 0.89
1.00 0.00 0.07 0.89
0.56 0.02 0.02 0.88
Score
1.0
0.8
0.6
0.4
0.2
0.0
Hospital
Restaurant
SISU
Tax