# Norma: rodada oficial v3 (E1–E3) com seis datasets

Correções, novas implementações, resultados e recomendações para a nova versão do artigo (VLDB)

Junio Freitas

15 de outubro de 2026; revisado em 19 de outubro de 2026

## Resumo

Reexecutamos os experimentos da Seção 6 do artigo do Norma (E1 classificação; E2 mapeamento; E3 fim a fim, **sem** o modo *document-level*) depois de um ciclo de correções e melhorias no sistema, no ground truth (GT) e na avaliação. A rodada cobre os **quatro datasets do artigo** (Hospital, Restaurant, SISU, Tax) e os **dois datasets HMDA** (HMDAZ e HMDA Checks), com **seis LLMs** via OpenRouter: GPT-6 Luna, DeepSeek-V4-Flash, Mistral Large 4, Qwen3.8-2.4T-A95B, GPT-6 Sol e Claude Sonnet 5.5. Cada configuração foi executada **uma vez**. Foram 138 jobs (36 do E1, 72 do E2, 12 do E3, mais 18 do modelo substituído), todos concluídos; o custo cobrado foi de US$ 82,94. Os números deste relatório já incorporam a correção da semântica das DCs de duas tuplas na tradução para SQL e a reavaliação das saídas gravadas, sem novas chamadas a LLM (Seção 7).

- **E1:** só três configurações atingem recall $\geq 0{,}90$ em todos os datasets. A escolhida é *Qwen3.8-2.4T-A95B + Examples* ($F_1$ médio 0,69), a mesma família e o mesmo prompt do artigo. O gargalo de recall é o HMDAZ (16 das 24 configurações acertam só 4 das 9 regras). Na HMDA Checks, sem contexto de tabela todos os modelos rotulam quase tudo como regra ($F_1$ 0,74 = classificador trivial).
- **E2:** nos quatro datasets do artigo, o Multi-Step volta a superar o Single-Prompt (CE 0,80 contra 0,75; AV 0,89 contra 0,55) e os melhores modelos novos superam o GPT-5 do artigo (Sonnet 0,84/0,97; Sol e Mistral 0,81/0,99; GPT-5 0,78/0,95). Nos HMDA, a extração por equivalência recupera boa parte do que a extração exata perde, e a aparente vantagem do Single-Prompt na AV da HMDA Checks é um artefato de concentração das violações.
- **E3:** Norma extrai as regras do GT em todos os datasets (CE 1,00 em Hospital e Tax; 0,58–0,59 na HMDA Checks). A AV agregada, porém, fica baixa no Tax (0,15) e no SISU com C+MS (0,11) por causa de *uma* DC ampla em cada caso; o classificador reduz o custo do pipeline de 1,6 a 5 vezes.
- **Avaliação:** em 4 dos 6 datasets uma única regra concentra de 78% a 99% das tuplas violadoras. Recomendamos reportar, ao lado da AV, o $F_1$ médio por regra e a equivalência por execução.
- **Correção na tradução para SQL:** as DCs de duas tuplas usavam `t1.tid < t2.tid`, o que perde violações de DCs assimétricas. Corrigido para `t1.tid <> t2.tid`; só o SISU muda (violações do GT de 487 para 533) e nenhuma conclusão se inverte.

# 1 Escopo, protocolo e execução

## 1.1 Datasets

| Dataset | Linhas usadas | Cols | Sent. | Regras | Tuplas viol. | Maior regra | Regras sem viol. |
|---|---|---|---|---|---|---|---|
| Hospital | 1.006 | 17 | 109 | 15 | 834 | 0,96 | 0 |
| Restaurant | 127.692 | 21 | 33 | 7 | 52.311 | 0,99 | 0 |
| SISU | 101.717 | 56 | 42 | 17 | 533 | 0,60 | 0 |
| Tax | 99.906 | 15 | 126 | 6 | 468 | 0,78 | 0 |
| HMDAZ | 1.000.000 (de 15,1M) | 135 | 17 | 9 | 209 | 0,54 | 1 |
| HMDA Checks | 1.000.000 (de 4,8M) | 81 | 158 | 92 | 986.491 | 0,99 | 68 |

**Tabela 1:** Datasets da rodada. "Regras" conta as sentenças com DC não nula no GT; "Maior regra" é a fração das tuplas violadoras marcadas pela maior regra do GT (concentração); "Regras sem viol." conta regras do GT sem nenhuma violação no recorte.

Os GTs dos quatro datasets do artigo não mudaram (as violações batem com a Tabela 2 do artigo). Os GTs dos HMDA foram revistos contra os documentos-fonte (Seção 2).

## 1.2 Modelos e substituições

| Modelo | Slug (OpenRouter) | US$/M tok. (entr./saída) | Chamadas | Custo (US$) |
|---|---|---|---|---|
| GPT-6 Luna | `openai/gpt-6-luna` | 0,10 / 0,50 | 854 | 0,77 |
| DeepSeek-V4-Flash | `deepseek/deepseek-v4-flash` | 0,09 / 0,18 | 871 | 0,74 |
| Mistral Large 4 | `mistralai/mistral-large-4-0` | 0,68 / 2,09 | 856 | 8,93 |
| Qwen3.8-2.4T-A95B | `qwen/qwen3.8-2.4t-a95b` | 2,00 / 6,00 | 913 | 17,32 |
| GPT-6 Sol | `openai/gpt-6-sol` | 2,00 / 10,00 | 3.142 | 36,02 |
| Claude Sonnet 5.5 | `anthropic/claude-sonnet-5.5` | 2,00 / 10,00 | 859 | 17,62 |
| MiniMax-M3 (substituído) | `minimax/minimax-m3` | 0,30 / 1,20 | 912 | 1,54 |
| Total | | | 8.407 | 82,94 |

**Tabela 2:** LLMs da rodada. O GPT-6 Sol tem mais chamadas porque também é o mapper do E3 (inclui a execução do E3 interrompida por falta de crédito). Custos medidos por requisição; o harness contabilizou US$ 85,82, porque inclui reservas de requisições abortadas.

A lista original tinha o **Kimi K2.6**. No *health check*, sob decodificação estrita por *JSON Schema*, ele emitia espaços em branco até o limite de tokens em dois passos do Multi-Step, em todos os provedores testados (6 de 6 falhas no roteamento padrão; 1 de 6 acertos no provedor bf16). Por decisão dos autores, foi substituído pelo **MiniMax-M3**, que passou no health check. No E2, porém, o MiniMax devolveu `{"results":[]}` para 107 das 156 sentenças do Single-Prompt v2, embora completasse o Multi-Step sem falhas; testado isoladamente, com prompt curto, respondia corretamente. Também por decisão dos autores, ele foi substituído pelo **Mistral Large 4**, o único entre quatro candidatos (MiMo-V2.6-Pro, Nemotron 3 Ultra, Seed 2.1 Turbo) que passou em todos os testes do health check *estendido*, que agora inclui o schema do Single-Prompt v2. Os resultados do MiniMax estão em `results/v3/superseded/`.

## 1.3 Protocolo

- **E1:** 4 prompts × 6 modelos × 6 datasets, lotes de 10 sentenças; seleção por recall $\geq 0{,}90$ em todos os datasets e maior $F_1$ médio.
- **E2:** Single-Prompt e Multi-Step (2 iterações de refinamento) só nas sentenças do GT. O Single-Prompt usa a versão melhorada (prompt `with_examples_v2`, lotes de 3, campo `violated_when`, seleção semântica de colunas com *embeddings* `text-embedding-3-large` e contexto de colunas). Seleção do mapper do E3: melhor Multi-Step em CE e AV.
- **E3:** C+MS e Multi-Step sobre todas as sentenças, com os componentes escolhidos.

- **Comum:** espaço de predicados v2 (sob demanda) em todos os datasets; saída estruturada estrita; no máximo 32.768 tokens de saída por chamada; 1 execução por configuração; DuckDB com limite de memória e tempo; primeiras 1M linhas dos HMDA.

### 1.4 Ocorrências durante a execução

Todas registradas em `results/v3/telemetry/20261013_215731_662134/CHANGES.md`:

1. Troca Kimi K2.6 → MiniMax-M3 antes de qualquer job do Kimi (orquestrador parado e retomado).
2. 13 erros transitórios de conexão, todos recuperados por novas tentativas com *backoff*.
3. Parada por falta de crédito no OpenRouter (HTTP 402) durante o E3. O job interrompido (Multi-Step na HMDA Checks) foi refeito do zero e o resultado parcial movido para `superseded`. O motivo de parada foi limpo à mão no `summary.json` para permitir a retomada.
4. Troca MiniMax-M3 → Mistral Large 4 e nova aplicação dos critérios de seleção do E3 (componentes inalterados).

## 2 O que mudou no Norma desde a submissão

### 2.1 Correções

1. **Método genérico.** O prompt do Multi-Step tinha exemplos que reproduziam sentenças do GT do HMDAZ e paráfrases do GT do Restaurant (vazamento de teste), e o código tinha quatro reparos fixos de HMDA (código → `*_name`, `rate_spread`, pontos percentuais e "exceed"). Os exemplos foram trocados por exemplos neutros e os reparos removidos; não restam referências fixas a datasets no código do método.
2. **Robustez dos mappers.** Validação com tipos (por exemplo, `rate_spread != 'NA'` é rejeitada); reparo de nós AND/OR unários ou vazios antes da validação; o Single-Prompt devolve ao modelo, uma vez, as regras inválidas com a mensagem de erro; o Multi-Step normaliza nomes de colunas e repergunta quando o JSON vem malformado.
3. **Falhas contadas.** Erros de SQL das regras previstas passam a ser contados, em vez de virarem "zero violações" em silêncio; o *predicate Jaccard* passa a ser calculado sobre os predicados-folha.
4. **GT dos HMDA.** *HMDAZ*: sentenças literais da Regulation Z de 2018, gatilhos HOEPA com as condições de cobertura, novas regras (*balloon*, amortização negativa, multa de pré-pagamento) e remoção da §1026.43(g)(1); 17 entradas, 9 com regra. *HMDA Checks*: realinhada ao guia de edições de 2014 do FFIEC, a mesma versão dos dados, com uma entrada por edição e as edições não verificáveis por registro como `null`; 158 entradas, 92 com regra (positivos no E1 caíram de 93% para 58%).

### 2.2 Novas implementações

1. **Espaço de predicados v2 (sob demanda).** O arquivo do dataset guarda só o esquema: tipo, operadores, operadores aritméticos, valores de domínio e uma descrição de cada coluna, escrita uma vez por LLM a partir de um perfil determinístico dos dados. Os predicados são gerados em tempo de execução só para as colunas selecionadas. Invariante testado: para os mesmos dados e opções, a geração é igual ao espaço v1 restrito às colunas. Nos datasets do artigo, a v2 reproduz a v1 exatamente (318, 414, 5.112 e 482 templates); no HMDAZ, evita materializar 590 mil templates.
2. **Glossário oficial.** As definições do FFIEC foram incorporadas às descrições de 36 colunas do HMDAZ (e das colunas de rótulo correspondentes).
3. **Single-Prompt v2.** Prompt `with_examples_v2` com contexto de colunas, semântica de violação e campo `violated_when`; seleção de colunas léxica, semântica ou híbrida. Na validação com GPT-6 Luna, a CE média em cinco datasets passou de 0,56 para 0,64.

4. **Avaliação.** (i) *Extração por equivalência lógica* ($CE_{\equiv}$): forma normal disjuntiva (IN↔OR, ordem dos operandos, distributiva, absorção) e unificação de literais código/rótulo apenas quando os dados confirmam que selecionam as mesmas linhas; os pares são descobertos nos dados. (ii) *Equivalência por execução*: fração das regras do GT (com $\geq 1$ violação) cuja regra prevista marca exatamente as mesmas linhas. (iii) $F_1$ *médio por regra.* (iv) *Concentração* da AV (`max_gold_rule_violation_share`) e regras do GT sem violação.

5. **Execução.** Health check estendido (classificador, os dois schemas do Single-Prompt e os cinco schemas do Multi-Step); opção `json_object_models` para modelos com decodificação estrita instável (implementada para o Kimi K2.6 e não usada na rodada final); controle de orçamento, paralelismo com exclusividade por modelo e limite de memória.

# 3 Hipóteses

H1. O espaço sob demanda com descrições de colunas melhora o mapeamento em esquemas largos sem alterar o resultado nos datasets do artigo.

H2. Parte do erro de extração nos HMDA é de forma, não de conteúdo (equivalência lógica, código ↔ rótulo); uma métrica de equivalência deve recuperá-la.

H3. A AV agregada é dominada pela regra mais violada; métricas por regra mudam a leitura dos resultados.

H4. O Multi-Step continua superior ao Single-Prompt mesmo depois das melhorias no Single-Prompt.

H5. O classificador continua útil no pipeline fim a fim, agora também em datasets grandes.

# 4 E1 — Classificação de sentenças

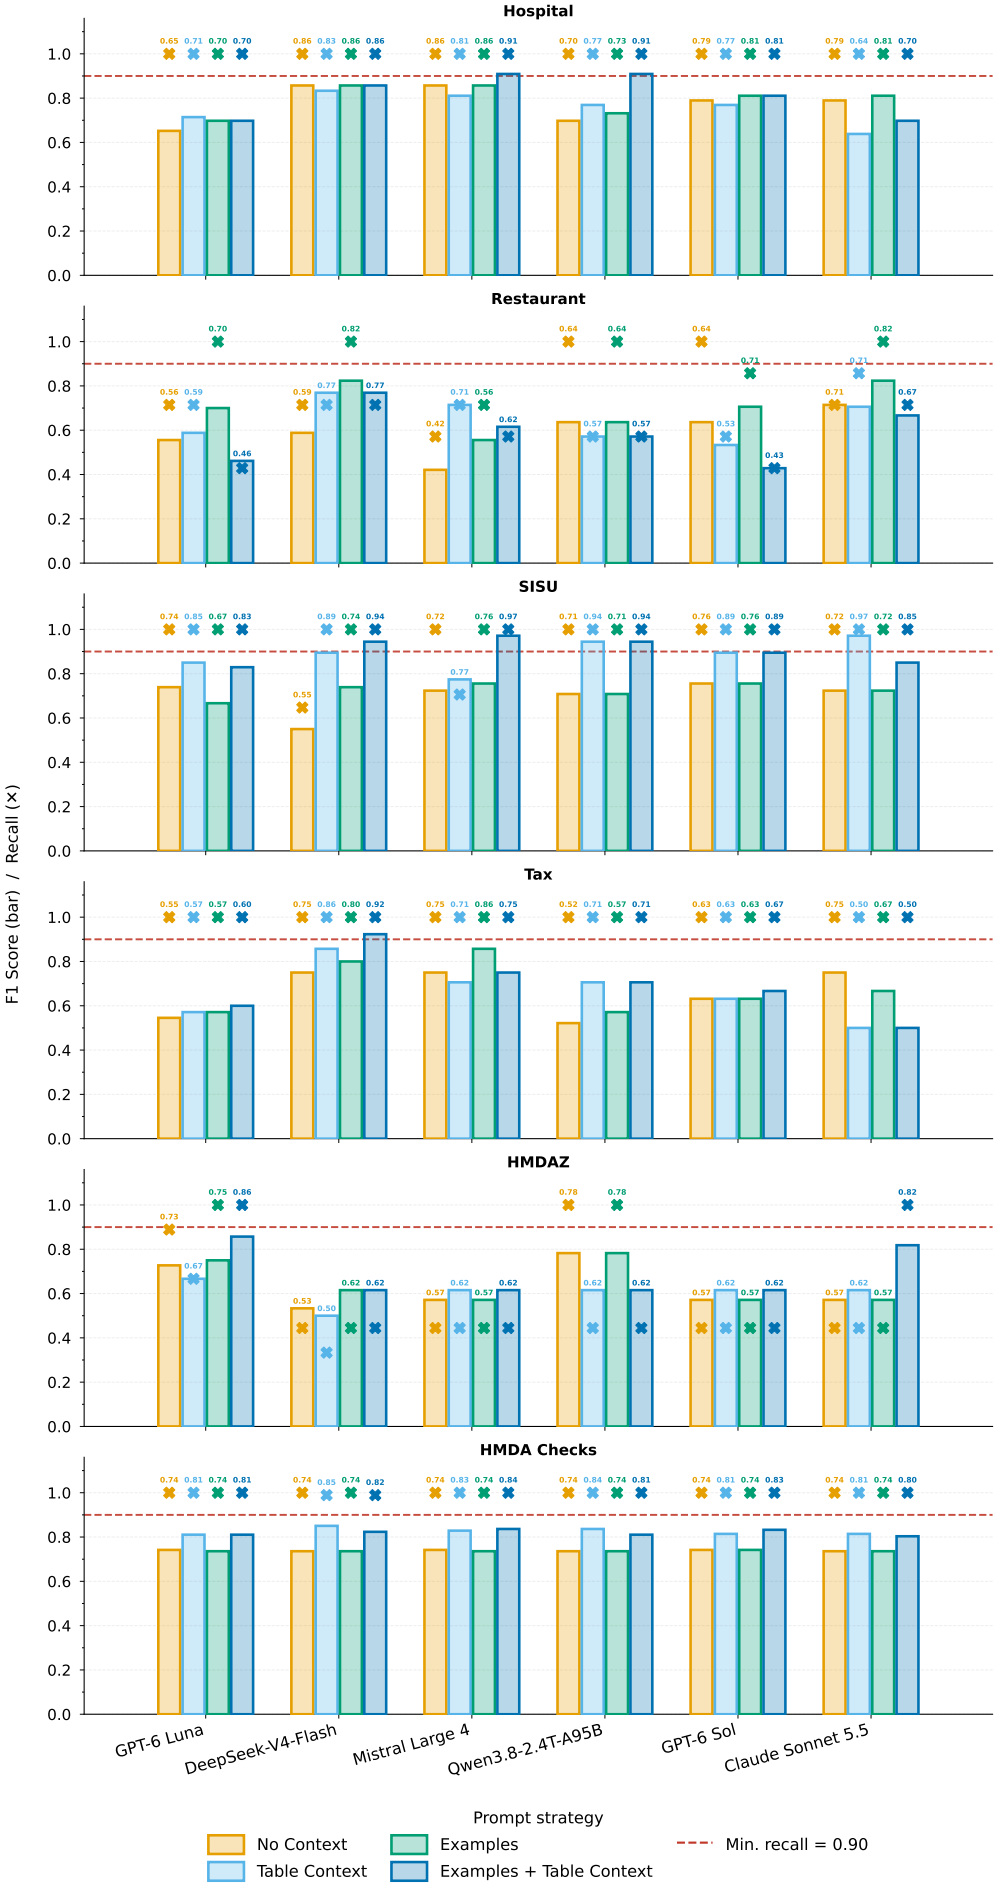



**Figura 1:** $F_1$ (barras) e recall (x) por modelo e prompt (formato da Figura 6 do artigo).

| Modelo | No Context | Table Context | Examples | Examples + Table |
|---|---|---|---|---|
| GPT-6 Luna | 0,66 (0,71) | 0,70 (0,67) | 0,69 (**1,00**) | 0,71 (0,43) |
| DeepSeek-V4-Flash | 0,67 (0,44) | 0,78 (0,33) | 0,76 (0,44) | 0,82 (0,44) |
| Mistral Large 4 | 0,68 (0,44) | 0,74 (0,44) | 0,72 (0,44) | 0,78 (0,44) |
| Qwen3.8-2.4T-A95B | 0,68 (**1,00**) | 0,74 (0,44) | **0,69 (1,00)** | 0,76 (0,44) |
| GPT-6 Sol | 0,69 (0,44) | 0,71 (0,44) | 0,70 (0,44) | 0,71 (0,43) |
| Claude Sonnet 5.5 | 0,71 (0,44) | 0,71 (0,44) | 0,72 (0,44) | 0,72 (0,71) |

**Tabela 3:** $F_1$ médio nos seis datasets e, entre parênteses, o menor recall. Só as configurações com menor recall 1,00 são elegíveis; em negrito, a escolhida.

**Achados do E1**

- **Critério do artigo aplicado:** elegíveis Qwen + Examples (0,694), Luna + Examples (0,687) e Qwen + No Context (0,680). A melhor média sem o critério (DeepSeek + Examples + Table, 0,82) perde mais da metade das regras do HMDAZ.
- **HMDAZ limita o recall:** as definições da Regulation Z ("um empréstimo é *high-cost* se…") soam como escopo, mas implicam condições verificáveis. 16 das 24 configurações acertam só 4 das 9.
- **HMDA Checks e o contexto de tabela:** sem contexto, $F_1 = 0{,}74$, o mesmo do classificador "tudo positivo". Com contexto de tabela, 0,80–0,85. As edições não verificáveis por registro só se distinguem pela estrutura do registro.
- **Comparação com o artigo (4 datasets):** $F_1$ médio de todas as configurações subiu de 0,69 para 0,72, mas a melhor elegível caiu (0,66 contra 0,85 do Qwen3-32B): os modelos novos aceitam mais sentenças, mantendo o recall e perdendo precisão (Tax, Restaurant).

## 5 E2 — Mapeamento

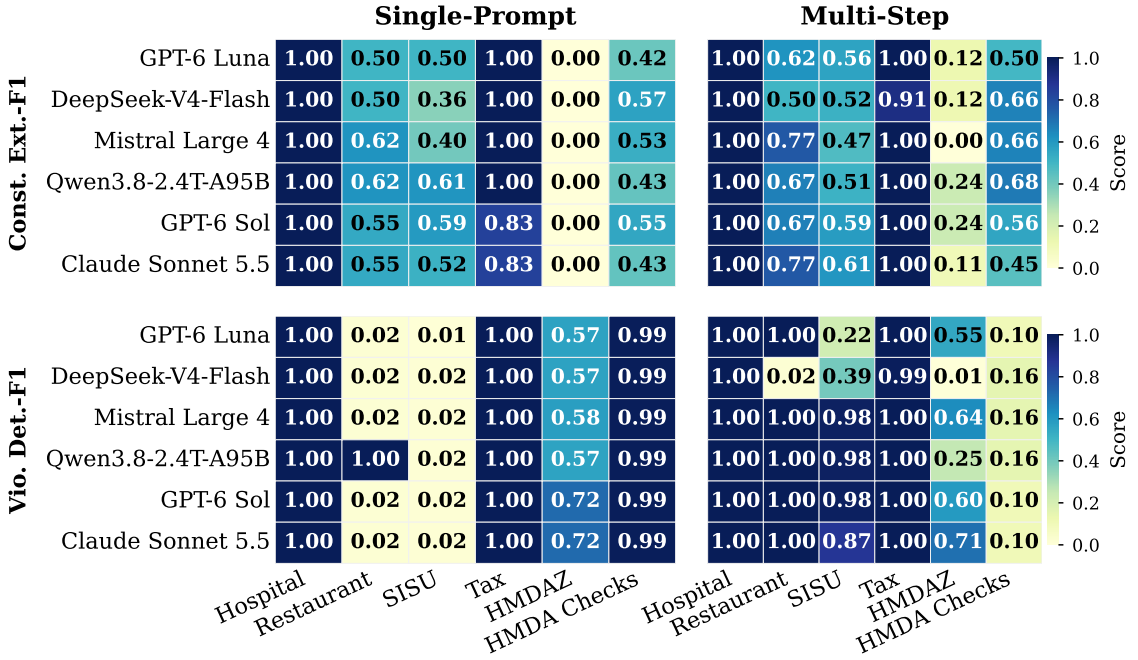



**Figura 2:** CE (extração exata) e AV (violação agregada) por modelo e mapper, só nas sentenças do GT (formato da Figura 7 do artigo).

| **Mapper** | **Model** | CE | $CE_{\equiv}$ | AV | Rule-$F_1$ | Exec. | Fail. |
|---|---|---|---|---|---|---|---|
| Single-Prompt | GPT-6 Luna | 0.57 | 0.69 | 0.60 | 0.78 | 0.75 | 0 |
| | DeepSeek-V4-Flash | 0.57 | 0.66 | 0.60 | 0.74 | 0.70 | 3 |
| | Mistral Large 4 | 0.59 | 0.66 | 0.60 | 0.73 | 0.71 | 0 |
| | Qwen3.8-2.4T-A95B | 0.61 | 0.70 | 0.76 | **0.86** | **0.83** | 0 |
| | GPT-6 Sol | 0.59 | 0.67 | 0.62 | 0.76 | 0.72 | 0 |
| | Claude Sonnet 5.5 | 0.55 | 0.64 | 0.62 | 0.76 | 0.70 | 0 |
| Multi-Step | GPT-6 Luna | 0.63 | 0.68 | 0.65 | 0.75 | 0.73 | 0 |
| | DeepSeek-V4-Flash | 0.62 | 0.64 | 0.43 | 0.68 | 0.67 | 0 |
| | Mistral Large 4 | 0.65 | 0.72 | **0.80** | 0.81 | 0.80 | 0 |
| | Qwen3.8-2.4T-A95B | **0.68** | 0.70 | 0.73 | 0.76 | 0.74 | 0 |
| | GPT-6 Sol | 0.67 | 0.71 | 0.78 | 0.80 | 0.79 | 0 |
| | Claude Sonnet 5.5 | 0.66 | **0.73** | 0.78 | 0.84 | 0.81 | 0 |

**Tabela 4:** Médias nos seis datasets. $CE_{\equiv}$: extração por equivalência; Rule-$F_1$: $F_1$ médio por regra; Exec.: equivalência por execução; Fail.: sentenças sem saída válida do modelo.

| | 4 datasets do artigo | | HMDAZ + HMDA Checks | |
|---|---|---|---|---|
| Métrica | Single-Prompt | Multi-Step | Single-Prompt | Multi-Step |
| CE | 0,75 | **0,80** | 0,24 | **0,36** |
| $CE_{\equiv}$ | 0,75 | **0,80** | **0,51** | 0,49 |
| AV | 0,55 | **0,89** | **0,81** | 0,29 |
| Rule-$F_1$ | 0,78 | **0,84** | **0,74** | 0,64 |
| Exec. | 0,77 | **0,83** | **0,67** | 0,61 |

**Tabela 5:** Médias sobre os seis modelos por grupo de datasets.

| | | Restaurant | | Tax | | Hospital | | HMDA Checks | |
|---|---|---|---|---|---|---|---|---|---|
| Mapper | Model | full | w/o | full | w/o | full | w/o | full | w/o |
| Single-Prompt | GPT-6 Luna | 0.02 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.99 | 0.77 |
| | DeepSeek-V4-Flash | 0.02 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.99 | 0.18 |
| | Mistral Large 4 | 0.02 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.99 | 0.74 |
| | Qwen3.8-2.4T-A95B | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.99 | 1.00 |
| | GPT-6 Sol | 0.02 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.99 | 0.18 |
| | Claude Sonnet 5.5 | 0.02 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.99 | 1.00 |
| Multi-Step | GPT-6 Luna | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.10 | 1.00 |
| | DeepSeek-V4-Flash | 0.02 | 1.00 | 0.99 | 0.96 | 1.00 | 1.00 | 0.16 | 0.77 |
| | Mistral Large 4 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.16 | 0.77 |
| | Qwen3.8-2.4T-A95B | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.16 | 0.77 |
| | GPT-6 Sol | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.10 | 1.00 |
| | Claude Sonnet 5.5 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.10 | 1.00 |

**Tabela 6:** Sensibilidade da AV do E2 à(s) regra(s) dominante(s): *full* = GT completo; *w/o* = sem a regra que marca $\geq 75\%$ das tuplas violadoras (Restaurant 99%, Tax 78%, Hospital 96%) ou, na HMDA Checks, sem as edições de data S270 e Q022. SISU e HMDAZ não têm regra dominante.

**Achados do E2**

- **H4 confirmada nos datasets do artigo.** Multi-Step supera o Single-Prompt melhorado em todas as métricas. Os melhores modelos superam o GPT-5 do artigo: Sonnet 0,84/0,97; Sol e Mistral 0,81/0,99.
- **Onde o Single-Prompt perde violações.** *Restaurant:* cinco dos seis modelos devolvem `null` para "pelo menos uma inspeção por ano", que concentra 99% das violações (recall 0,01); sem essa regra, todos chegam a 1,00. *SISU:* o Single-Prompt identifica o estudante pela inscrição do ENEM em vez do CPF nas regras entre duas tuplas e marca cerca de 51 mil tuplas contra 533 (precisão $< 0{,}01$).
- **H2 confirmada.** A $\mathrm{CE}_{\equiv}$ praticamente não muda os datasets do artigo, mas nos HMDA eleva a CE de 0,24 para 0,51 (Single-Prompt) e de 0,36 para 0,49 (Multi-Step).
- **H3 confirmada (HMDA Checks).** O Single-Prompt marca AV 0,99 e o Multi-Step 0,10–0,16. Duas edições de data (S270, Q022) marcam 99% das tuplas violadoras, que cobrem 98,6% das linhas: uma DC que marca *todas* as tuplas já obtém 0,99. O Multi-Step devolve `null` para as duas; a maioria das DCs do Single-Prompt marca todas as linhas (por exemplo, `action_taken_date / 10000 != activity_year`, sempre verdadeira em divisão real). Sem essas duas edições, a ordem se inverte (tabela de sensibilidade acima).
- **H1 (espaço sob demanda).** Não foi testada diretamente nesta rodada, que usou só a v2. Nos datasets do artigo, o invariante garante o mesmo vocabulário da v1. No HMDAZ, a evidência vem da validação anterior com GPT-6 Luna: a AV do Multi-Step passou de 0,18 (v1) para 0,68 (v2). Para afirmar isso no artigo, seria preciso uma ablação v1 $\times$ v2 com os modelos finais.
- **Escolha do mapper do E3.** Nenhum modelo lidera em CE e AV (Qwen CE 0,68; Mistral AV 0,80). Pela média das duas: Sol 0,727, Mistral 0,722, Sonnet 0,718, Qwen 0,707. Escolhido o GPT-6 Sol; com uma execução por configuração, é um empate técnico entre os quatro.

# 6 E3 — Fim a fim

| Family | Method | Constr. Classification | | | Constr. Extraction | | | Viol. Discovery | | |
|---|---|---|---|---|---|---|---|---|---|---|
| | | P | R | $F_1$ | P | R | $F_1$ | P | R | $F_1$ |
| | | | | **Hospital** | | | | | | |
| Norma | C+MS | 0.83 | 1.00 | **0.91** | 1.00 | 1.00 | **1.00** | 1.00 | 1.00 | **1.00** |
| | Multi-Step | 0.71 | 1.00 | 0.83 | 1.00 | 1.00 | **1.00** | 1.00 | 1.00 | **1.00** |
| Profiling | DC Discovery | n/a | n/a | n/a | 0.00 | 0.00 | 0.00 | 0.83 | 1.00 | 0.91 |
| Text2SQL | XiYan-SQL | 0.50 | 1.00 | 0.67 | 0.60 | 1.00 | 0.75 | 0.83 | 1.00 | 0.91 |
| | | | | **Restaurant** | | | | | | |
| Norma | C+MS | 1.00 | 0.71 | **0.83** | 0.80 | 0.57 | **0.67** | 1.00 | 1.00 | **1.00** |
| | Multi-Step | 1.00 | 0.71 | **0.83** | 0.80 | 0.57 | **0.67** | 1.00 | 1.00 | **1.00** |
| Profiling | DC Discovery | n/a | n/a | n/a | 0.00 | 0.00 | 0.00 | 0.77 | 0.87 | 0.82 |
| Text2SQL | XiYan-SQL | 0.86 | 0.75 | 0.80 | 0.17 | 0.12 | 0.14 | 0.45 | 0.64 | 0.52 |
| | | | | **SISU** | | | | | | |
| Norma | C+MS | 0.84 | 0.94 | **0.89** | 0.59 | 0.59 | **0.59** | 0.06 | 0.97 | 0.11 |
| | Multi-Step | 0.75 | 0.88 | 0.81 | 0.53 | 0.53 | 0.53 | 0.79 | 0.96 | **0.87** |
| Profiling | DC Discovery | n/a | n/a | n/a | 0.00 | 0.00 | 0.00 | 0.00 | 0.99 | 0.01 |
| Text2SQL | XiYan-SQL | 1.00 | 0.65 | 0.79 | 0.45 | 0.29 | 0.36 | 0.00 | 1.00 | 0.01 |
| | | | | **Tax** | | | | | | |
| Norma | C+MS | 0.60 | 1.00 | **0.75** | 1.00 | 1.00 | **1.00** | 0.08 | 1.00 | **0.15** |
| | Multi-Step | 0.60 | 1.00 | **0.75** | 1.00 | 1.00 | **1.00** | 0.08 | 1.00 | **0.15** |
| Profiling | DC Discovery | n/a | n/a | n/a | 0.00 | 0.00 | 0.00 | 0.00 | 0.94 | 0.01 |
| Text2SQL | XiYan-SQL | 0.40 | 1.00 | 0.57 | 0.29 | 0.67 | 0.40 | 0.01 | 1.00 | 0.02 |
| | | | | **HMDAZ** | | | | | | |
| Norma | C+MS | 1.00 | 0.67 | **0.80** | 0.25 | 0.22 | 0.24 | 0.47 | 0.71 | 0.56 |
| | Multi-Step | 1.00 | 0.67 | **0.80** | 0.50 | 0.33 | **0.40** | 0.58 | 0.94 | **0.72** |
| Profiling | DC Discovery | – | – | – | – | – | – | – | – | – |
| Text2SQL | XiYan-SQL | – | – | – | – | – | – | – | – | – |
| | | | | **HMDA Checks** | | | | | | |
| Norma | C+MS | 0.94 | 0.89 | **0.92** | 0.65 | 0.53 | 0.58 | 1.00 | 0.05 | 0.10 |
| | Multi-Step | 0.92 | 0.90 | 0.91 | 0.67 | 0.53 | **0.59** | 1.00 | 0.05 | **0.10** |
| Profiling | DC Discovery | – | – | – | – | – | – | – | – | – |
| Text2SQL | XiYan-SQL | – | – | – | – | – | – | – | – | – |

**Tabela 7:** Formato da Tabela 3 do artigo, sem o modo *document-level*. Componentes: Qwen3.8-2.4T-A95B + Examples e GPT-6 Sol Multi-Step. Os baselines dos quatro datasets do artigo são os do artigo (mesmos dados e GT); nos HMDA não foram executados (–).

| Dataset / variante | $CE_{\equiv}$ | Rule-$F_1$ | Exec. | DCs previstas | DCs em não-regras | Custo (US$) |
|---|---|---|---|---|---|---|
| Hospital C+MS / MS | 1,00 / 1,00 | 1,00 / 1,00 | 1,00 / 1,00 | 18 / 21 | 3 / 6 | 0,46 / 2,25 |
| Restaurant C+MS / MS | 0,67 / 0,67 | 0,57 / 0,57 | 0,57 / 0,57 | 5 / 5 | 0 / 0 | 0,30 / 0,77 |
| SISU C+MS / MS | 0,61 / 0,56 | 0,87 / 0,76 | 0,82 / 0,71 | 19 / 20 | 3 / 5 | 0,91 / 1,95 |
| Tax C+MS / MS | 1,00 / 1,00 | 1,00 / 1,00 | 1,00 / 1,00 | 10 / 10 | 4 / 4 | 0,38 / 1,91 |
| HMDAZ C+MS / MS | 0,27 / 0,40 | 0,53 / 0,55 | 0,50 / 0,50 | 6 / 6 | 0 / 0 | 0,90 / 1,46 |
| HMDA Checks C+MS / MS | 0,72 / 0,72 | 0,83 / 0,80 | 0,83 / 0,83 | 87 / 90 | 5 / 7 | 3,35 / 9,85 |

**Tabela 8:** Métricas complementares do E3 (por regra, sobre as regras do GT) e custo de cada execução.

**Achados do E3**

- **Extração forte em todos os datasets**, inclusive nos HMDA: CE 1,00 em Hospital e Tax; 0,58–0,59 na HMDA Checks, com classificação $F_1$ 0,92 e equivalência por execução 0,83.
- **H5 parcialmente confirmada.** O C+MS melhora a precisão da classificação (Hospital 0,83 contra 0,71; SISU 0,84 contra 0,75; HMDA Checks 0,94 contra 0,92) e reduz as DCs geradas para não-regras, mas o ganho é menor que no artigo: o *rule gate* do Multi-Step já rejeita a maioria das não-regras. Em compensação, o classificador **reduz o custo de 1,6 a 5 vezes**.
- **Uma DC ampla derruba a AV.** *Tax:* as 6 regras do GT saem exatas, mas 4 das 120 sentenças distratoras (escritas por LLM para parecer regra) passam pelo classificador e pelo *gate* e geram DCs que marcam 5,6 mil tuplas (AV 0,15). *SISU (C+MS):* uma regra extra entre duas tuplas usa a inscrição do ENEM como chave e a execução marca 9,2 mil tuplas contra 533 do GT (AV 0,11 contra 0,87 do Multi-Step).
- **HMDAZ:** C+MS pior que Multi-Step (CE 0,24 contra 0,40). Cada variante aceita uma sentença diferente (o classificador descarta o *balloon payment*; o *gate* descarta o gatilho de pontos e taxas) e as DCs do gatilho de APR diferem entre execuções: variação de uma execução única.

# 7 Correção da tradução de DCs para SQL e reavaliação

Ao detalhar a compilação de DCs em SQL para a nova versão do artigo, encontramos um defeito no tradutor (`src/dbms/sql_translator.py`). As DCs de duas tuplas eram compiladas como uma autojunção com `t1.tid < t2.tid`, para não comparar uma tupla consigo mesma nem reportar o mesmo par duas vezes. Isso só está correto para DCs *simétricas*, como as dependências funcionais. Numa DC assimétrica, como "maior nota não pode ter pior classificação", os pares violadores em que a tupla de menor `tid` é a de nota menor ficam de fora. O texto do artigo (Exemplo 1) já usava a forma correta (`<>`); era o código que divergia dele.

| Regra do GT (duas tuplas, assimétrica) | Tuplas com `<` | Tuplas com `<>` |
|---|---|---|
| SISU: classificação em ordem decrescente de nota (Art. 19) | 9 | **61** (76 pares) |
| Tax: mesmo ZIP, ganha menos mas paga taxa maior | 2 | **4** |

**Tabela 9:** As duas regras do GT afetadas. As outras 22 regras de duas tuplas dos datasets do artigo são simétricas e não mudam; nos HMDA, a reavaliação não mostrou nenhuma mudança.

**Correção.** A condição passou a ser `t1.tid <> t2.tid`. Como as violações são contadas por tupla, enumerar as duas ordens não infla as contagens. Foi acrescentado um teste de regressão com um caso assimétrico; os 80 testes passam.

**Reavaliação.** As saídas gravadas do E2 e do E3 foram reavaliadas com o mesmo `MappingEvaluator`, sem chamadas a LLM e sem custo (`results/v3_reeval/reevaluate.py`). Os resultados originais em

`results/v3/` foram preservados. Todas as diferenças, valor a valor, estão em `results/v3_reeval/CHANGES_*.csv`. Classificação, extração exata e extração por equivalência não dependem da execução e não mudam.

| Métrica (SISU) | Antes | Depois |
|---|---|---|
| Tuplas violadoras do GT (Tabela 2) | 487 | 533 |
| Concentração da maior regra | 0,65 | 0,60 |
| E2 Multi-Step, AV: Sonnet / Sol / Mistral / Qwen | 0,92 / 1,00 / 0,99 / 0,99 | 0,87 / 0,98 / 0,98 / 0,98 |
| E2 Qwen, $F_1$ por regra (Multi-Step / Single-Prompt) | 0,76 / 0,77 | 0,81 / 0,83 |
| E3 AV (C+MS / Multi-Step) | 0,13 / 0,94 | 0,11 / 0,87 |

**Tabela 10:** Principais mudanças. Hospital, Restaurant, Tax, HMDAZ e HMDA Checks não mudam além de arredondamento: nas regras assimétricas do Tax, as tuplas recuperadas já violavam outras regras.

**Efeito nas conclusões.** Nenhuma se inverte. A escolha do mapper do E3 continua com o GPT-6 Sol (média de CE e AV: Sol 0,727; Mistral 0,722; Sonnet 0,718; Qwen 0,707), e a média do Multi-Step nos quatro datasets do artigo passa de 0,90 para 0,89 de AV. As métricas por regra do Qwen sobem, porque ele é um dos modelos que acertam a regra assimétrica do SISU, que agora conta inteira. As Figuras 6 e 7, a tabela de métricas e a Tabela 3 deste relatório e do artigo foram regeneradas a partir de `results/v3_reeval`.

**Ponto para o artigo original.** A Tabela 2 da submissão anterior (SISU com 487 violações) usava o mesmo código e, portanto, subestimava as violações dessa regra. As comparações entre métodos daquela versão continuam justas, porque GT e predições eram avaliados com a mesma semântica.

# 8 Insights para a nova versão do artigo

1. **Mensagem central mantida e ampliada.** O desenho sentença a sentença com mapeamento em etapas continua o mais robusto e agora escala para esquemas de 135 colunas e 1M de linhas; é o único método com extração alta em todos os seis datasets.
2. **Espaço sob demanda como contribuição de sistema.** Mostra como tornar o vocabulário controlado viável em esquemas largos sem perder a garantia de que a saída pertence ao espaço.
3. **Avaliação mais honesta.** Reportar a concentração da AV por dataset e complementar a AV com $F_1$ por regra e equivalência por execução; reportar $CE_{\equiv}$ ao lado da CE exata (no Text-to-SQL, o análogo é a execução *versus* o *exact match*). Isso responde diretamente a críticas sobre a métrica agregada.
4. **Novos datasets reais e difíceis.** HMDAZ e HMDA Checks são pares texto–tabela reais, públicos e grandes; ajudam a responder às críticas de que Hospital e Tax têm texto gerado por LLM (R3-O3, R2-O6).
5. **Classificador como filtro de custo.** Além da qualidade, o classificador reduz o custo do pipeline de 1,6 a 5 vezes.
6. **Falhas de modelo como achado.** Dois modelos falharam com saída estruturada estrita em formas diferentes (laço de espaços; respostas vazias com prompt longo). Vale uma frase sobre a necessidade de *health checks* específicos por formato de saída.
7. **Compilação para SQL como parte do método.** A nova §5.4 do artigo mostra que transformar uma DC em consulta exige decisões que afetam o resultado: semântica de pares, tipos, `NULL`, limites de execução e inferências entre texto e dados (valores em milhares, `rate_spread` como APR−APOR, rótulo × código, CPF × inscrição do ENEM). Isso fortalece o argumento de contribuição metodológica pedido pelos revisores (R2-O2, R2-O3, R1-O5, R3-O2).
8. **Variação entre execuções.** Com uma execução por configuração, diferenças de poucos centésimos entre os melhores modelos (Sol, Mistral, Sonnet, Qwen) não são conclusivas; recomenda-se declarar isso ou, se o orçamento permitir, repetir as configurações finalistas.

# 9 Limitações e ameaças à validade

- Uma execução por configuração; os modelos de raciocínio não são determinísticos (nas validações anteriores, desvio de até ±0,07).
- Baselines (DC Discovery, XiYan-SQL) não foram reexecutados; nos datasets do artigo, os números vêm da submissão anterior (mesmos dados e GT); nos HMDA, ausentes.
- HMDA Checks: as colunas de data parecem sintéticas (uniformes entre 2010 e 2024 com `activity_year` 2014), e 68 das 92 regras não têm violação no recorte, o que limita as métricas por execução a 24 regras.
- O glossário oficial só existe para o HMDAZ; os demais datasets não receberam conhecimento externo.
- O custo das *embeddings* da seleção semântica de colunas não é contabilizado pelo harness (centavos).
- O modo *document-level* não foi avaliado e foi retirado do artigo na versão v4.
- A análise de sensibilidade da AV foi calculada antes da correção da semântica de pares; ela cobre Restaurant, Tax, Hospital e HMDA Checks, que não mudaram com a correção.

# 10 O que foi alterado no artigo

Há duas versões novas, ambas em cópias (a pasta original da submissão não foi modificada). A versão final é a **v4**:

- `results/v3/paper/`: primeira atualização (seções 5 e 6 com a rodada v3 e Related Work revisado);
- `results/v3/paper_v4/`: **versão final**, que parte da anterior, remove o modo *document-level* e incorpora a reavaliação;
- `results/v3/paper_v4_diff/`: a v4 com as diferenças marcadas (`latexdiff`) em relação à submissão SIGMOD, em todas as seções alteradas.

O arquivo principal VLDB (`text2Constraints_vldb2027.tex`) passou a incluir todas as seções da versão SIGMOD. Alterações em relação à submissão:

- **Introdução:** a lista de contribuições cita a classificação e o mapeamento por sentença e a compilação das DCs em consultas SQL, sem o modo *document-level*. O Exemplo 1 informa que a consulta do Artigo 19 do SISU retorna 76 pares violadores envolvendo 61 candidatos (nota R2-O1 dos revisores).
- **Background e Overview:** só a granularidade por sentença; a figura do pipeline perdeu a seta e o rótulo do modo *document-level* (editados diretamente no PDF, preservando as fontes), e a legenda e o texto foram ajustados.
- **§5 (mapping):** categoria de predicados aritméticos; espaço de predicados sob demanda com descrições de colunas (e glossário no HMDAZ); Single-Prompt com recuperação semântica de colunas, `violated_when` e validação por esquema; agora duas variações de mapper.
- **Nova §5.4, "From Denial Constraints to SQL"** (no lugar de *Document-level mapping*): estrutura das regras (AND/OR e regras independentes), compilação (seleção ou autojunção com $t_1.tid \neq t_2.tid$, `IN`/`LIKE`, aritmética, divisão protegida), tipos e valores ausentes (`TRY_CAST`, lógica de três valores), execução com limites e as inferências entre texto e dados. Inclui uma tabela com seis regras reais do GT de cinco datasets, com o SQL gerado pelo Norma e o número de tuplas violadoras.
- **§6 (avaliação):** seis datasets (Tabela 2 com HMDAZ e HMDA Checks, SISU com 533 violações); métricas complementares; configuração com OpenRouter e os seis modelos; E1, E2 e E3 com

texto, Figuras 6 e 7, tabela de métricas de mapeamento e Tabela 3 regeneradas; nenhuma menção ao modo *document-level*.

- **§7 (Related Work):** mesma estrutura e tamanho próximo (cerca de 500 palavras, contra 416); 20 referências novas, entre elas descoberta aproximada de DCs (PVLDB 2026), REEs e Rock, geração de regras com LLMs, regulatory NLP com LLMs, verificação de Text-to-SQL, NL2SQL em português, geração de OCL e Doc2DB. Saíram Bohannon 2007 e Breaux 2008, redundantes. A nota R3-O1/R1-O1 dos revisores foi atendida.
- **Não alterados:** resumo e conclusão, que não citam números nem modelos. As notas `\altic` dos revisores foram preservadas para os autores.